Исследование эффективности применения агентских систем в задаче генерации научных обзоров

Обсуждение направлений ВКР

CMC MSU

9 апреля 2026 г.

План выступления

1. Проблематика
2. Постановка задачи
3. Формализация критериев качества
4. Направления исследования
5. Масштаб и планирование

Историческая рамка

2023–2026: Активное развитие мультиагентных пайплайнов для генерации обзоров (AutoSurvey, SurveyForge, SurveyX, SurveyGen-I).

Среди мотиваций архитектурной сложности значимое место занимало:

- Ограниченное контекстное окно LLM ($\sim$4K–32K токенов)
- Невозможность подать большое число источников за один проход
- Декомпозиция задачи как обход ограничения

2025–2026: контекстные окна выросли на порядок:

- Gemini 2.5 Pro — 2M токенов
- Claude Opus, GPT-5 — 200K токенов
- В 1M помещается $\sim$100–150 полных научных статей

Следствие: одна из значимых исходных мотиваций для агентского подхода ослабла.

Центральный вопрос работы

Мотивация

Если ограничение, породившее агентские системы, во многом снято — какие функции у этих систем остаются?

Формулировка через концептуальное разложение:

Мультиагентный пайплайн можно условно разложить на:

- **Поиск** – Подбор источников по запросу, по которым будет строиться обзор
- **Синтез** – генерация текста на основе источников

Важно понимать, что в зависимости от протокола взаимодействия агентов эти функции могут быть нечетко разделены.

Подвопросы:

1. Является ли агентский подход *только* продвинутым многостадийным поисковиком?
2. Или агентность вносит дополнительный вклад в *качество самой генерации*, недостижимый классическими путями?

Центральная гипотеза

Гипотеза H_0 (нулевая): При компетентной реализации классического бейзлайна с длинным контекстом, разрыв между агентными системами и бейзлайном на стандартной задаче незначителен.

$$\text{Quality}(S_{\text{agent}}) \approx \text{Quality}(S_{\text{base}}) \quad \text{при} \quad \text{Cost}(S_{\text{agent}}) \gg \text{Cost}(S_{\text{base}})$$

Гипотеза H_1 (альтернативная): Агентский подход содержит дополнительную ценность. Причем ценность может проявляться или усиливаться при усложнении задачи. (назовем гипотезой H_2)

$$\text{Quality}(S^{\text{hard}}_{\text{multi}}) > \text{Quality}(S^{\text{hard}}_{\text{single}})$$

Структура проверки:

1. Стандартная задача (SurGE, абстракты) $\rightarrow$ проверка H_0
2. Усложнённая задача (SurGE, полные тексты) $\rightarrow$ проверка H_2

Карта направлений в свете гипотезы

Направление	**Роль в проверке гипотезы**
1. Cost-quality систем	Центральная проверка H_0 на стандартной задаче
2. Baseline	Реализация компетентного классического бейзлайна для проверки H_0
3. Полные тексты	Усложнение задачи для проверки H_2
4. Dual-Track Critic Memory	Дополнение к основным гипотезам. Борьба с проблемой *Lost In The Middle*
5. U-образное управление памятью	Дополнение к основным гипотезам. Улучшение Cost-quality соотношения

Направления не равноправны: 1 и 2 центральны, 3 расширяет проверку, 4 и 5 предлагают возможные варианты решения проблем.

Общая формулировка

Задача. Построение структурированного обзора S по теме Q на основе научного корпуса C с учётом ограничений формата F.

Входные объекты:

- Тема Q — описание предметной области
- Корпус $C = \{p_1, \ldots, p_N\}$, где $p_i = (\text{meta}_i, \text{content}_i)$
- Ограничения F — объём, структура, стиль

Выходной объект:

$$S = (s_1, s_2, \ldots, s_m), \quad s_i \in \text{Sections with inline citations}$$

Искомое отображение:

$$f : (Q, C, F) \to S, \quad \max_f \text{Quality}(S)$$

Постановка 1A: EndToEnd с факторизацией пайплайна

Условие: retrieval и generation разделимы.

$$f = G \circ R, \quad R : (Q, C) \to C_Q \subset C, \quad G : (Q, C_Q, F) \to S$$

Какие системы соответствуют:

- SurveyX – retrieval полностью отделён, AttributeTree работает с уже найденным
- HiReview – статический граф цитирования, затем генерация
- LiRA – FAISS-индекс строится один раз, ревизия не ищет новых статей
- AutoSurvey – Поиск для каждой подсекции (в рамках генерации подсекции)
- SurveyForge – Поиск для каждой подсекции (в рамках генерации подсекции)

Данные: SurGE (Su et al., 2025): $|C| = 1{,}086{,}992$ публикаций arXiv CS, $|Q| = 205$ тем.
Ограничение: retrieval recall SurGE $\approx 8\%$ – верхний предел полноты.

Постановка 1B: неделимый EndToEnd

Не выполнение условия: во многих системах retrieval и generation переплетены.

$$f : (Q, C, F) \to S, \quad \text{retrieval вызывается итеративно внутри } f$$

Какие системы соответствуют:

- AutoSurvey – Поиск для каждой подсекции
- SurveyForge – Поиск для каждой подсекции
- SurveyG – Evaluation Agent после генерации формулирует новые поисковые запросы (до 3 итераций)
- STORM – retrieval при каждом раунде диалога персон (web search)

Следствие для эксперимента: итеративный retrieval – часто невозможно изолировать от генерации.

Постановка 2: изолированный synthesis

Редуцированная задача: стадия R устраняется, C_Q фиксируется.

$$G : (Q, C_Q, F) \to S$$

Способы построения C_Q:

- $C_Q = \mathrm{Refs}(S^*)$ — ground-truth ссылки эталона
- $C_Q = \mathrm{Refs}(S^*) \cup \mathrm{Noise}$ — смесь с тематически близким шумом

Режим представления публикаций (параметр эксперимента):

- Abstract-only: $\mathrm{content}_i = \mathrm{abstract}_i$ (стандартная задача)
- Full-text: $\mathrm{content}_i = \mathrm{full\ PDF}_i$ (усложнённая задача)
- Гибрид: abstract + intro + conclusion; или abstract + retrieved chunks

Ключевое преимущество: изоляция качества synthesis от качества retrieval, что помогает точнее диагностировать вклад агентности в генерацию.

Критерии качества: четыре оси

Качество S оценивается по четырём независимым осям:

Ось	**Что измеряет**
Базовое качество	связность, лаконичность, структурная целостность
Подтверждённость	соответствие фактов цитируемым источникам
Типовой профиль	распределение видов утверждений по категориям
Стоимость	кол-во токенов, время на генерацию, денежный эквивалент, число вызовов

Детализация каждой оси — в следующем разделе.

Ось 1: базовое качество генерации

Сравнение с эталоном S^*:

- **ROUGE-L**(S, S^*) — для сопоставимости с существующей литературой
- **BERTScore**(S, S^*) — семантическое сходство, backbone `deberta-xlarge-mnli`

LLM-as-judge на основе аспектов из SummEval (Fabbri et al., TACL 2021):

$$\text{G-Eval}_d(S) = \sum_{k=1}^{5} k \cdot P_{\text{LLM}}(\text{score} = k \mid S, \text{rubric}_d)$$

где $d \in \{\text{coherence, consistency, fluency, relevance}\}$.

Метрики SurGE для сопоставимости с базовыми линиями:

- *SQS*, *SHR* – Схожесть структуры доклада с эталоном
- *CQS* – Абстрактное качество обзора, оцениваемое LLM по специфичным для задачи критериям

Ось 2: подтверждённость утверждений (ALCE)

ALCE (Gao et al., EMNLP 2023). Работает на уровне утверждений с inline-ссылками.
Для утверждения c с цитированиями $\mathrm{Cite}(c) = \{p_1, \ldots, p_k\}$:

$$\mathrm{CitRecall}(c) = \mathbb{I}\left[\mathrm{NLI}\left(\bigcup_i p_i \models c\right)\right]$$ – подтверждается ли c своими источниками?

$$\mathrm{Redundant}(p_j, c) = \mathbb{I}\left[\mathrm{NLI}\left(\bigcup_{i \neq j} p_i \models c\right)\right]$$ – нужен ли источник p_j, или c и без него подтверждено?

$$\mathrm{CitPrecision}(c) = 1 - \frac{|\{p_j : \mathrm{Redundant}(p_j, c)\}|}{|\mathrm{Cite}(c)|}$$ – доля действительно необходимых источников

Итоговые метрики обзора:

$$\overline{\mathrm{CitRecall}}(S) = \frac{1}{|\mathcal{C}(S)|} \sum_c \mathrm{CitRecall}(c) \quad \text{и} \quad \overline{\mathrm{CitPrecision}}(S) = \frac{1}{|\mathcal{C}(S)|} \sum_c \mathrm{CitPrecision}(c)$$

Ось 2: подтверждённость (FActScore)

FActScore (Min et al., EMNLP 2023). Работает на уровне атомарных фактов.

Три шага:

1. Декомпозиция: $\text{Decompose}(S) = \{a_1, a_2, \ldots, a_n\}$ через Claimify
2. Retrieval: $e_i = \text{Retrieve}(a_i, C_Q)$
3. Верификация: $\text{Support}(a_i, e_i) \in \{0, 1\}$ через AlignScore

Итоговая метрика:

$$\text{FActScore}(S) = \frac{1}{n} \sum_{i=1}^{n} \text{Support}(a_i, e_i)$$

AlignScore как backend (Zha et al., ACL 2023):

- RoBERTa-based, 355M параметров (`alignscore-large`)
- Унифицированная функция alignment: NLI + QA + fact verification + STS
- Работает с длинным контекстом через chunking + max-pooling
- Существенно дешевле T5-11B AutoAIS, сопоставимое качество

Ось 3: типовой профиль утверждений

Извлечение: $\text{Decompose}(S) \to \{a_1, \ldots, a_n\}$ через Claimify.

Классификация $\phi : a_i \to \{A, B, C, D\}$ через LLM-as-judge:

- A Общие тематические (следуют из абстракта)
- B Методологические уточнения (требуют раздела methods)
- C Количественные (конкретные числа из results)
- D Критические / сравнительные (discussion, limitations)

Метрики профиля:

$$\pi_k(S) = \frac{|\{a_i : \phi(a_i) = k\}|}{n}, \quad k \in \{A, B, C, D\}$$

$$\text{FActScore}_k(S) = \frac{\sum_{i:\phi(a_i)=k} \text{Support}(a_i, e_i)}{|\{a_i : \phi(a_i) = k\}|}$$

Гипотеза при замене абстрактов→full-text доли π_B, π_C растут без падения $\text{FActScore}_B, \text{FActScore}_C$, и этот рост сильнее у агентских систем.

Ось 4: ресурсная стоимость

Базовые метрики на один обзор:

$$
\begin{aligned}
T_{\text{in}}(S) &= \text{input tokens} \\
T_{\text{out}}(S) &= \text{output tokens} \\
T_{\text{reason}}(S) &= \text{reasoning tokens (если применимо)} \\
\text{Cost}(S) &= \alpha \cdot T_{\text{in}} + \beta \cdot T_{\text{out}} + \gamma \cdot T_{\text{reason}} \\
\tau(S) &= \text{wall-clock time, seconds} \\
K(S) &= \text{число вызовов LLM}
\end{aligned}
$$

Stage breakdown: все метрики разбиваются по стадиям pipeline

$$T_{\text{in}}(S) = T_{\text{in}}^{\text{retr}} + T_{\text{in}}^{\text{outline}} + T_{\text{in}}^{\text{draft}} + T_{\text{in}}^{\text{revise}}$$

Интегральная метрика эффективности:

$$\text{CER}_M(S) = \frac{M(S)}{\text{Cost}(S)}$$

где M — любая метрика качества. Визуализация — кривая Парето в осях (Cost, Quality).

Направление 1: cost-quality (центральная проверка H_0)

Проблематика. В литературе по survey generation систематического cost-quality анализа нет:

- SurveyForge — единичная точка в appendix ($<$ \$0.50 на 64K-обзор)
- AutoSurvey — репортит скорость, не стоимость
- SurveyX, SurveyGen-I — cost-анализ отсутствует
- Никто не строил кривую Парето для нескольких систем

Актуальность. Прямо отвечает буквальной формулировке темы и проверяет H_0 количественно.

Решение.

- Системы: AutoSurvey, SurveyForge/STORM, компетентная одноагентная baseline (направление 2), naive RAG
- Модели: дешёвая (GPT-4o-mini) и дорогая (GPT-4o/Claude)
- Все метрики качества и стоимости (оси 1–4)
- Ablation по компонентам: какие стадии можно удалить без потери качества
- Визуализация: кривая Парето (Cost, Quality)

Направление 2: компетентный не агентский baseline (вторая половина проверки H_0)

Проблематика. Архитектуры AutoSurvey/SurveyForge/SurveyX унаследованы из эпохи малых контекстов. Сегодня RAG генерация с расширенным контекстом возможна, но сравнений в литературе нет.

Методологическое требование: baseline должен быть сильным для честного сравнения.

Компоненты компетентной одноагентной baseline:

- Расширенный контекст: весь C_Q за один или несколько вызовов
- Chain-of-though
- Итеративная генерация *большими блоками* с сохранением полного контекста между вызовами
- Prompt engineering

Роль в работе: сравнение baseline с мультиагентными системами на стандартной задаче (направление 1) — основной эмпирический тест H_0.

Направление 3: усложнение задачи (проверка H_2)

Проблематика. SurGE и публичная версия AutoSurvey работают только с абстрактами. Это юридически-техническое решение, не научное. Модель не видит methods, results, discussion.

Логика для H_2. Если H_0 подтвердилось (на стандартной задаче разрыва нет), это ещё не закрывает вопрос: возможно, агенты вносят ценность только на более сложных задачах. Полные тексты увеличивают объём и сложность синтеза.

Решение: двумерная сетка экспериментов.

	Abstract-only	**Full-text**
Агентская система	E_{11}	E_{12}
Одноагентная baseline	E_{21}	E_{22}

Ключевой тест:

$$(E_{12} - E_{11}) \overset{?}{>} (E_{22} - E_{21})$$

Если левая часть существенно больше — агенты лучше используют дополнительную сложность $\Rightarrow$ поддержка H_2. Если разрыв симметричен — агентность не даёт уникальной ценности даже в сложных условиях.

Направление 4: Dual-Track Critic Memory

Мотивация: Улучшение качества агентской генерации за счет модификации механизма памяти для борьбы с проблемами обработки длинных и разнородных контекстов.
Проблематика. Существующие критики передают обратную связь как единый текст, смешивая фактологические и стилистические правки. Накопление смешанной обратной связи ведет котравлению контекста.
Решение: архитектура с двумя хранилищами.

$$M = M_{\text{epi}} \sqcup M_{\text{proc}}$$

- M_{epi}: фактологические корректировки
- M_{proc}: стилистические и структурные правила
- Фаза drafting: контекст $=$ prompt $\cup\, M_{\text{epi}}$
- Фаза polishing: контекст $=$ prompt $\cup\, M_{\text{proc}}$

Теоретическая рамка: Cognitive Load Theory (Sweller) + CoALA (Sumers et al., TMLR 2024).

Направление 5: U-образное управление памятью

Проблематика. Современные системы расходуют контекстное окно равномерно по фазам генерации, не учитывая, что разные фазы требуют разного объёма поддержки. Это приводит к избыточному расходу токенов и стоимости.

Источник аналогии. В когнитивной литературе (Коровкин и др., 2018, 2023) наблюдается U-образная динамика загрузки рабочей памяти при решении инсайтных задач: выше на старте и финале, ниже в середине. Это *вдохновляет* гипотезу для агентов, но не доказывает её.

Гипотеза: U-образное распределение ресурсов даёт экономию суммарной стоимости *без потери качества*:

$$\mathrm{Cost}(S_{\mathrm{U}}) < \mathrm{Cost}(S_{\mathrm{flat}}) \quad \text{при} \quad \mathrm{Quality}(S_{\mathrm{U}}) \approx \mathrm{Quality}(S_{\mathrm{flat}})$$

Дополнительный аргумент (вторичный): меньше памяти в середине $\Rightarrow$ меньше проблем с Lost in the Middle (Liu et al., TACL 2024).

Направление 5: реализация и стратегии сужения

Конкретные стратегии сужения контекста в средней фазе:

- Генерация изолированными блоками, с малым количесвом фактологической информации в контексте
- Интеграция с Dual-Track Critic Memory: в середине использовать только M_{epi}, исключая M_{proc}. То есть в середине важны только факты, при объединении вспоминаем про стиль.

Сравнение по двум осям одновременно:

- Стоимость: $\text{Cost}(S_{\text{U}})$ vs $\text{Cost}(S_{\text{flat}})$
- Качество: все метрики осей 1–3

Возможные исходы:

- *Положительный:* экономия без потери качества $\Rightarrow$ U-управление работает
- *Отрицательный:* экономия с ухудшением $\Rightarrow$ средние секции требуют полного контекста
- *Нюансированный:* расхождение метрик $\Rightarrow$ диагностика того, какой тип информации важен в средней фазе

Структурная совместимость направлений

Эмпирическая группа (1 + 2 + 3). Разделяют инфраструктуру:

- Один набор тем из SurGE
- Один pipeline прогона систем и логирования стоимости
- Один набор метрик оценки
- Различаются только оси анализа

Архитектурная группа (4 + 5). Содержит расширения:

- Реализация поверх AutoSurvey/SurveyForge
- Proof-of-concept масштаб
- Улучшают агентские системы

Спасибо за внимание